DESENVOLVIMENTO DE PROTÓTIPO DE SEMÁFORO INTELIGENTE COM VISÃO COMPUTACIONAL E TINYML PARA OTIMIZAÇÃO ADAPTATIVA DO FLUXO DE VEÍCULOS

Autores: Arthur Feitosa Nogueira, Gustavo Alves, Jhonatan Ricardo, Pietro Augusto e Samuel Deak Luiz

1. INTRODUÇÃO

O controle de tráfego em ambientes urbanos permanece um desafio crítico de mobilidade e sustentabilidade. Sistemas semafóricos convencionais, baseados em temporização fixa, geram ineficiências significativas, como paradas desnecessárias em vias de baixo fluxo. Visando superar a rigidez desses modelos, este relatório técnico detalha a **Versão 2.0** de um semáforo inteligente, que evolui do sistema baseado em sensores infravermelhos (IR) para uma solução de **Visão Computacional** alimentada por Inteligência Artificial (IA) embarcada (TinyML).

O projeto utiliza um microcontrolador **ESP32-CAM** para realizar a detecção e classificação de veículos em tempo real. O objetivo é otimizar dinamicamente o fluxo em um cruzamento, priorizando uma via principal (Avenida Principal) e garantindo a abertura da via secundária (Rua Secundária) somente após a **detecção visual e confirmação de presença de um veículo**.

A principal inovação desta versão é a substituição da detecção por sensores de barreira pela análise de imagem. Essa abordagem elimina a necessidade de infraestrutura física intrusiva na via, como sensores indutivos ou de infravermelho instalados no pavimento ou em postes, necessitando apenas da câmera visual para monitoramento e tomada de decisão. O sistema foi implementado e validado em uma maquete, simulando um ambiente urbano em escala.

1. INTRODUCTION

Traffic control in urban environments remains a critical challenge for mobility and sustainability. Conventional traffic light systems, based on fixed timing, generate significant inefficiencies, such as unnecessary stops on low-flow roads. Aiming to overcome the rigidity of these models, this technical report details **Version 2.0** of a smart traffic light, which evolves from the system based on infrared (IR) sensors to a **Computer Vision** solution powered by embedded Artificial Intelligence (AI) (TinyML).

The project uses an **ESP32-CAM** microcontroller to perform real-time vehicle detection and classification. The objective is to dynamically optimize the flow at an intersection, prioritizing a main road (Main Avenue) and ensuring the opening of the secondary road (Secondary Street) only after **visual detection and confirmation of a vehicle's presence**.

The main innovation of this version is the replacement of barrier sensor detection with image analysis. This approach eliminates the need for intrusive physical infrastructure on the road, such as inductive or infrared sensors installed on the pavement or poles, requiring only the

visual camera for monitoring and decision-making. The system was implemented and validated on a mock-up, simulating an urban environment to scale.

2. JUSTIFICATIVA (FOCO EM IA)

A transição para a Visão Computacional por meio da plataforma Edge Impulse é justificada pela busca por maior robustez, flexibilidade e capacidade de escalabilidade do sistema.

Enquanto o sensor IR fornece apenas uma detecção binária (presença/ausência de obstáculo em um ponto fixo), a IA embarcada no ESP32-CAM permite:

- **Detecção Não Invasiva:** Não requer contato físico com o ambiente da via, simplificando a instalação e manutenção.
- **Aumento de Precisão:** O modelo de Machine Learning pode ser treinado para classificar especificamente "carro", "moto" ou "caminhão", ignorando pedestres, animais ou detritos, o que não é possível com sensores IR passivos.
- **Inferência na Borda (Edge Computing):** O processamento da imagem é realizado diretamente no microcontrolador (TinyML), garantindo baixíssima latência na tomada de decisão do semáforo, sem depender de conectividade constante com a nuvem, o que é crucial para sistemas críticos de tráfego.

A IA se torna o cerne da inteligência do semáforo, permitindo a contagem e, futuramente, a medição da densidade de veículos para ajustes dinâmicos e mais refinados nos tempos de sinal.

3. MATERIAIS E MÉTODOS (HARDWARE E EDGE IMPULSE)

3.1. Hardware e Componentes

A unidade de processamento central (UCP) foi substituída pelo módulo **ESP32-CAM (ESP-32S com câmera OV2640)**, devido à sua capacidade de processamento de imagem, conectividade Wi-Fi e baixo custo.

Componentes Utilizados:

- **1x Módulo ESP32-CAM:** CPU e plataforma de Visão Computacional.
- **1x Módulo FTDI ou ESP32-CAM-MB:** Necessário para a programação serial do ESP32-CAM.
- **6x LEDs (2 VERMELHOS, 2 AMARELOS E 2 VERDES):** Para a sinalização do tráfego.
- **6x Resistores 220R:** Para segurança dos LEDs
- **1x Protoboard 400 Pontos:** Para montagem e prototipagem do circuito.
- **Jumpers:** Para conexões.

Conexões e Integração ao Sistema:

O ESP32-CAM, por operar em lógica de 3.3V, requer atenção especial nas conexões. Os LEDs de cada semáforo são conectados aos pinos de **GPIO (General Purpose Input/Output)** do ESP32, que atuam como saídas digitais para acionamento.

Semáforo	Cor do LED	Pino GPIO Sugerido (Saída)
Principal (1)	Verde	GPIO 2
Principal (1)	Amarelo	GPIO 4
Principal (1)	Vermelho	GPIO 14
Secundário (2)	Verde	GPIO 12
Secundário (2)	Amarelo	GPIO 13
Secundário (2)	Vermelho	GPIO 15

Obs.: Os pinos GPIO 0 e GPIO 2 são críticos para o modo de programação e *boot*, respectivamente, e devem ser manuseados com cuidado.

3.2. Adaptação do Diagrama Elétrico

O diagrama elétrico é adaptado da configuração original do Arduino para o ESP32-CAM. A principal alteração é a substituição do microcontrolador e a conexão das saídas digitais para o acionamento dos LEDs do semáforo. O ESP32-CAM é programado via **Módulo FTDI** (utilizando uma **Baud Rate** de 115200) ou um ESP32-CAM-MB e deve ser configurado no modo de *flash* (GPIO 0 em *LOW*) antes do *upload* do código. A alimentação pode ser feita via pino VCC (5V ou 3.3V, dependendo do módulo e da fonte). Segue abaixo o esquema elétrico:

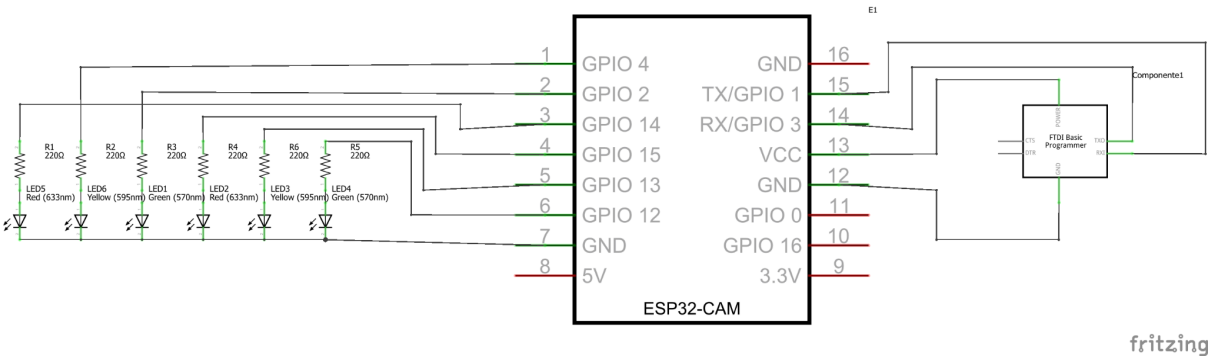

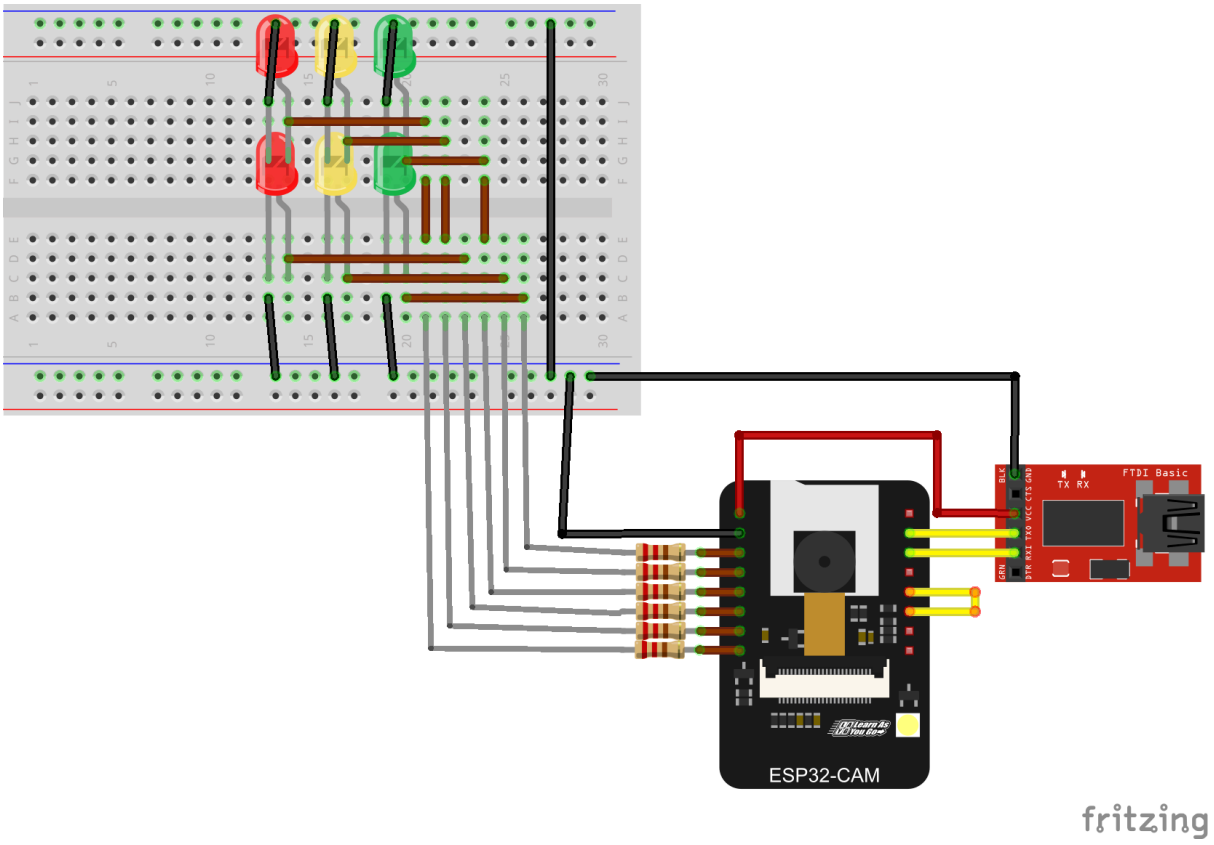

3.3. Metodologia de IA com Edge Impulse (TinyML)

O treinamento do modelo de Visão Computacional foi realizado na plataforma **Edge Impulse**, seguindo as etapas de Machine Learning para Microcontroladores (TinyML):

1. **Coleta de Dataset:** Foram tiradas centenas de fotos da maquete, variando as condições (com e sem veículos, diferentes posições, iluminação)

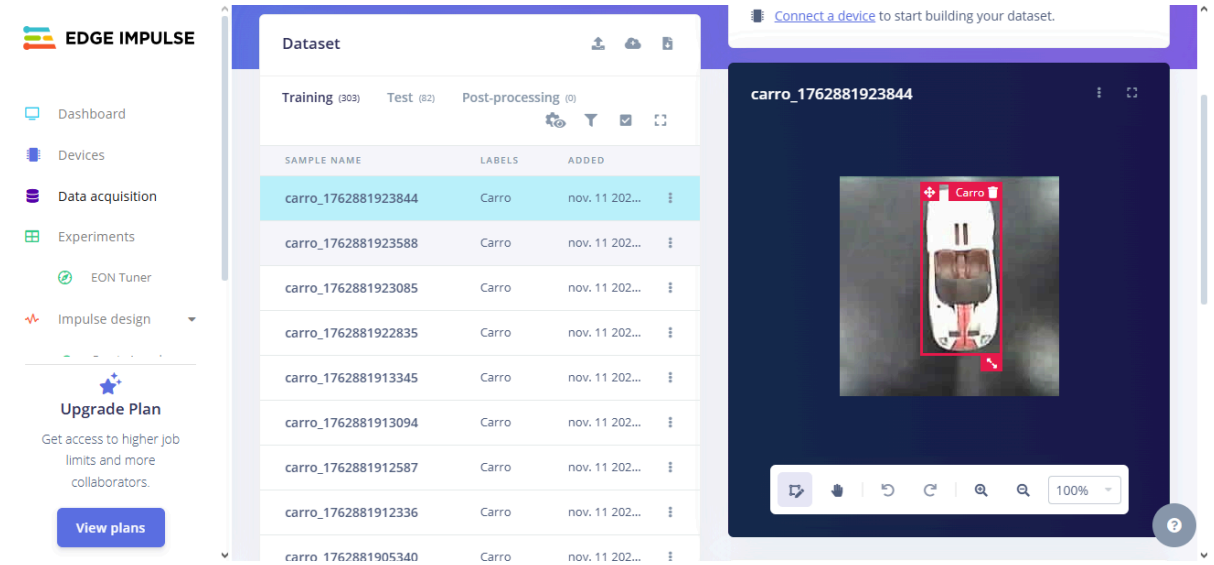

.

2. **Rotulagem (Labeling):** No Edge Impulse, as imagens foram rotuladas (ex: "carro", "vazio"). A rotulagem precisa é fundamental para o sucesso da inferência.

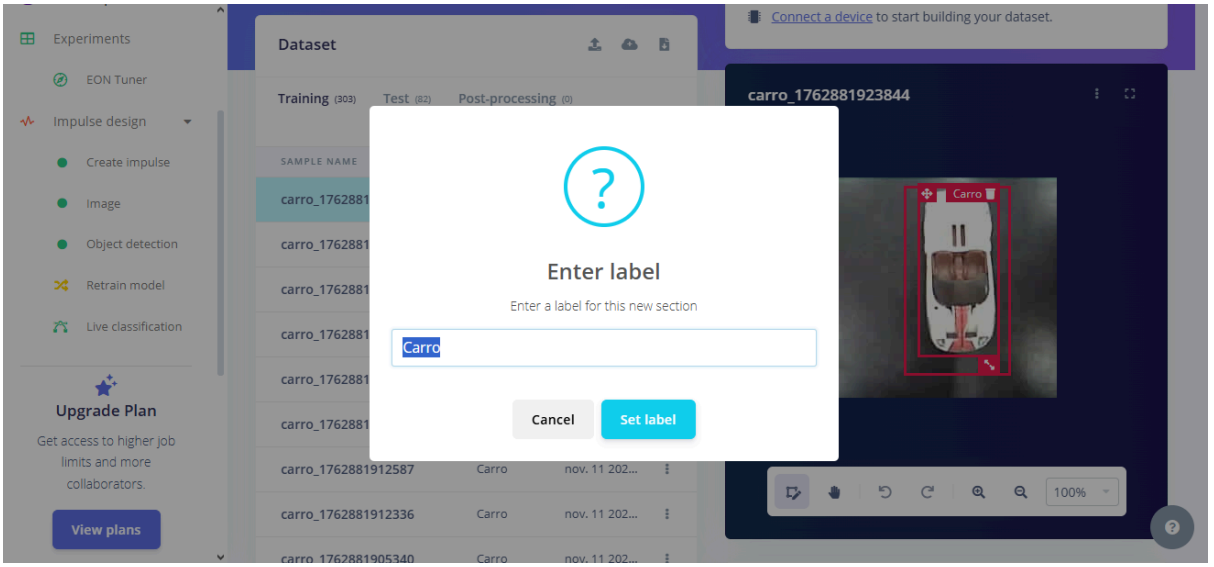

3. **Criação do Impulso:** Definiu-se o *pipeline* de processamento, incluindo *Image Data* (redimensionamento para 96x96 ou 160x160) e a etapa de *Classification* (Rede Neural Convolucional - CNN).

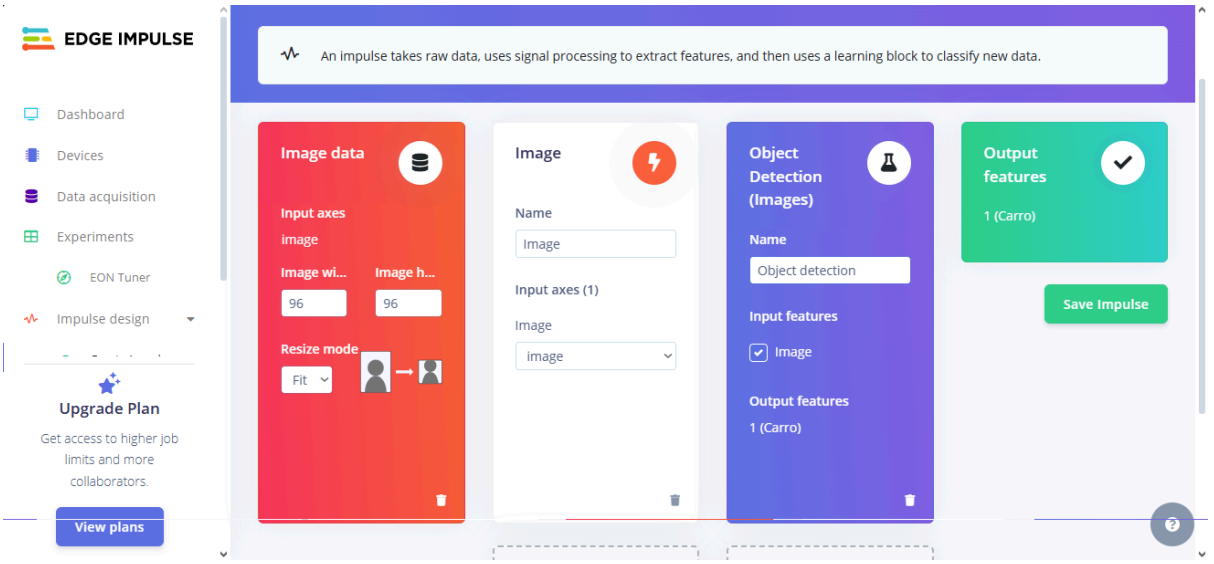

4. **Mudança das imagens para escala de cinza:** O ESP-32 CAM, por ser um hardware de baixo custo, é recomendado a mudança das imagens para escala de cinza, para que se atinja maior desempenho da IA.

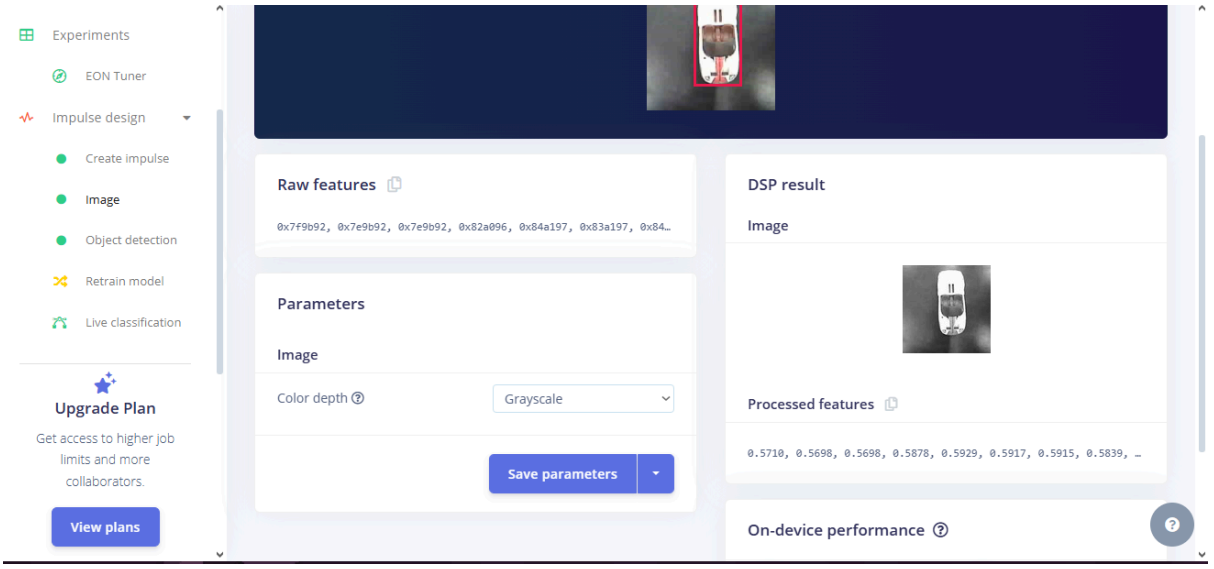

5. **Treinamento do Modelo:** Foi utilizado um modelo otimizado para *on-device* inferência, como o **MobileNetV2** (ou um modelo customizado e eficiente em termos de memória), treinado para classificar as imagens. O treinamento envolveu diversas **Épocas** até se atingir uma precisão satisfatória (acima de 90%).

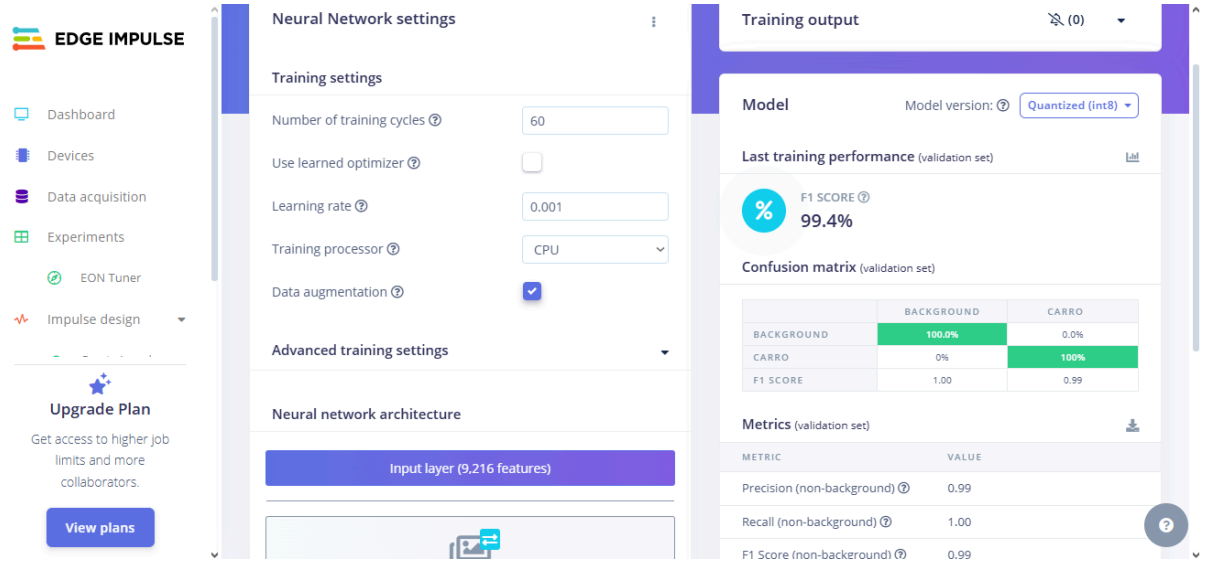

6. **Deploy (Implantação):** Após o treinamento e validação, o modelo foi exportado como uma **Biblioteca Arduino (Edge Impulse library)**. Este código é então integrado à IDE do Arduino e *flasheado* no ESP32-CAM.

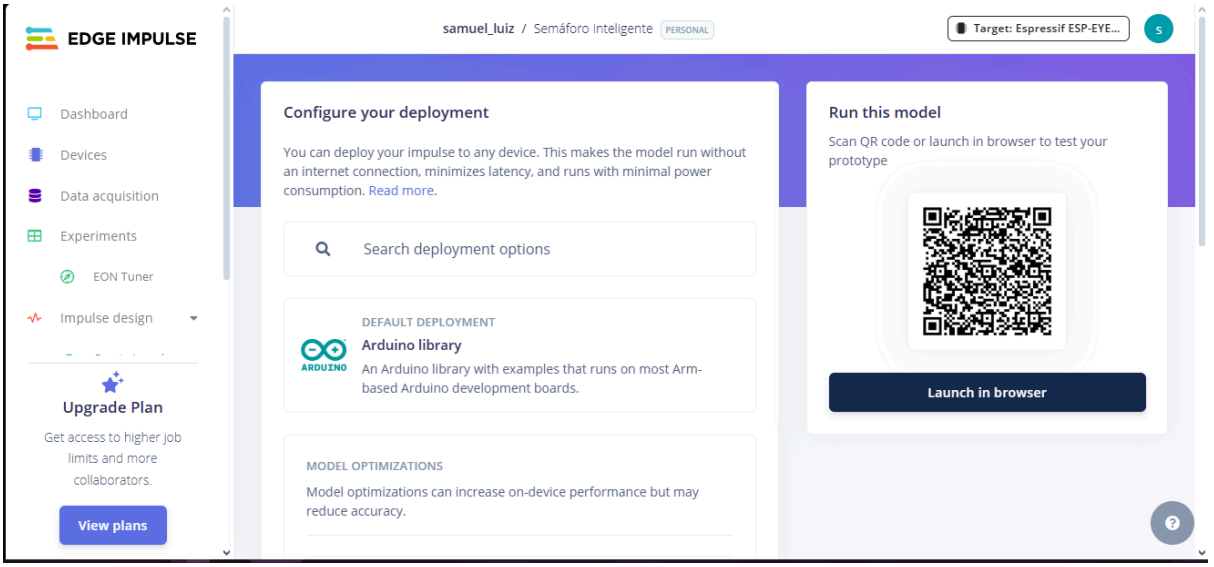

O processo de **Inferência** é a execução do modelo treinado, realizada **na borda** (*on-device*), sem necessidade de comunicação externa após o *deploy*. A câmera captura o *frame*, a UCP executa a inferência e devolve a probabilidade de cada *label* (ex: 85% 'carro', 15% 'vazio').

4. LÓGICA DE CONTROLE

A lógica de controle implementada no *firmware* do ESP32-CAM gerencia o fluxo de tráfego com base no resultado da inferência da IA. O sistema opera em um cruzamento de duas vias de mão única (Avenida Principal e Rua Secundária).

4.1. Fluxograma de Operação

1. **Estado Padrão (Prioridade):**
    - **Avenida Principal (Semáforo 1): VERDE**.
    - **Rua Secundária (Semáforo 2): VERMELHO**.
2. **Detecção de Veículo (Gatilho):**
    - O ESP32-CAM monitora continuamente o *feed* de vídeo focado na Rua Secundária.
    - **Gatilho de Ação:** Se a **Inferência da IA** detectar o *label* **"carro"** com uma **confiança (probabilidade) maior que 70%**.
3. **Transição de Fechamento da Via Principal:**
    - Ao detectar o gatilho, o Semáforo 1 (Avenida Principal) inicia o ciclo de fechamento:
        - **VERDE** > **AMARELO** (Tempo de retardo: 2 segundos).
        - **AMARELO** > **VERMELHO**.
4. **Abertura da Via Secundária:**
    - Imediatamente após o Semáforo 1 fechar (Vermelho), o Semáforo 2 (Rua Secundária) abre:
        - **VERMELHO** > **VERDE**.
5. **Período de Abertura e Retorno:**
    - O Semáforo 2 permanece em **VERDE** por um tempo pré-determinado (X segundos) ou enquanto a Inferência da IA continuar a reportar a presença de "carro" com alta confiança.
    - **Retorno ao Padrão:** Após o período de abertura (ou se a detecção de "carro" cair abaixo de 70% por um período de segurança), o Semáforo 2 fecha:
        - **VERDE** > **AMARELO** (Tempo de retardo: 2 segundos).
        - **AMARELO** > **VERMELHO**.
    - O Semáforo 1 retorna imediatamente para o estado **VERDE**, reiniciando o ciclo no Estado Padrão.

5. REPRESENTAÇÃO VISUAL

Para a apresentação e validação visual do projeto, foi construída uma maquete em uma base de isopor de 60x60 cm. O asfalto foi representado por E.V.A. de cor cinza e áreas verdes foram decoradas com grama E.V.A. A câmera foi colocada como um poste com suas fiações ligadas aos postes dos leds.

5.1 Projeto da maquete em 3D

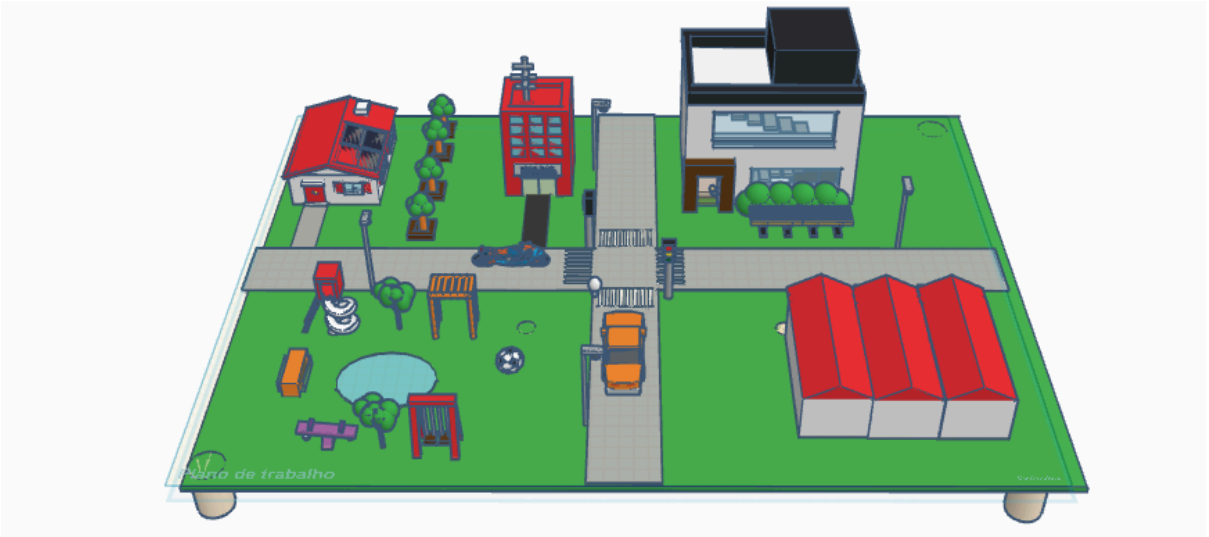

6. CONCLUSÃO

O desenvolvimento do protótipo de semáforo inteligente com ESP32-CAM e TinyML (Edge Impulse) demonstra a viabilidade e eficácia da Visão Computacional para sistemas adaptativos de gerenciamento de tráfego. O projeto alcançou o objetivo de otimizar o fluxo, substituindo a detecção simplista por IR por uma **Inferência** de IA mais precisa e adaptável, que opera de forma eficiente **na borda**.

A implementação valida o potencial do TinyML como uma solução de baixo custo para problemas complexos de infraestrutura urbana, eliminando a dependência de sensores físicos invasivos e fornecendo dados ricos para a tomada de decisão do controlador. Trabalhos futuros devem se concentrar no aprimoramento do modelo de IA para contagem de veículos, o que permitiria o ajuste dinâmico do tempo de abertura dos sinais (em vez de tempo fixo X), e na integração de módulos de comunicação para a criação de uma rede semafórica urbana robusta.

REFERÊNCIAS

1. PARANÁ. Secretaria da Educação. **Aula 04: Semáforo inteligente**. 2021. Disponível em: https://aluno.escoladigital.pr.gov.br/sites/alunos/arquivos_restritos/files/documento/2021-07/aula04_semaforo_inteligente_m2.pdf. Acesso em: 14 ago. 2025.
2. PARANÁ. Secretaria da Educação. **Aula 30: Sensor de obstáculo**. 2021. Disponível em: https://aluno.escoladigital.pr.gov.br/sites/alunos/arquivos_restritos/files/documento/2021-05/aula_30_sensor_obstaculo.pdf. Acesso em: 14 ago. 2025.
3. ESPRESSIF SYSTEMS. **ESP32 Series Datasheet**. Versão 4.3. Xangai: Espressif Systems, 2023. Disponível em: https://www.espressif.com/sites/default/files/documentation/esp32_datasheet_en.pdf.
4. GHAZAL, B.; ELKADRI, R.; AL KHALIL, K.; BAZZI, A. **Smart traffic light control system**. In: THIRD INTERNATIONAL CONFERENCE ON ELECTRICAL, COMPUTER, COMMUNICATIONS, AND MECHATRONICS ENGINEERING (ICECCME), 2023. IEEE, 2023.
5. SANDLER, Mark et al. **MobileNetV2: Inverted Residuals and Linear Bottlenecks**. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2018. Disponível em: https://arxiv.org/abs/1801.04381.